1 Klasyfikacja

1.1 Wstępna analiza i preprocesing danych

W pierwszej fazie prac przeprowadzono szczegółową analizę eksploracyjną zbioru danych ortodontycznych. Zbiór składa się z 446 obserwacji oraz 27 zmiennych. Zmienne objaśniające (26 cech) stanowią numeryczne pomiary twarzoczaszki pacjentów, zarejestrowane w dwóch okresach rozwoju: w 9. i 12. roku życia (są to m.in. kąty SN/MP, Facial axis, Y-axis, SNB, SNA, ANB czy stosunek AFH:PFH). Zmienną celu jest kategoryczna cecha określająca kierunek wzrostu (*growth direction*) zawierająca 3 klasy: horizontal, normal, vertical.

1.1.1 Kompletność danych i rozkład zmiennej celu

Weryfikacja kompletności zbioru (na podstawie analizy wartości *Null*) wykazała całkowity brak braków w danych dla każdej z 27 kolumn. W związku z tym, na etapie preprocesingu nie było konieczności stosowania żadnych technik uzupełniania danych.

Analiza rozkładu klas dla zmiennej docelowej *growth direction* ujawniła znaczne zjawisko niezrównoważenia klas. Wystąpienia poszczególnych klas prezentują się następująco:

- **normal** - 246 obserwacji,
- **horizontal** - 184 obserwacje,
- **vertical** - zaledwie 16 obserwacji.

Zdecydowana niedoreprezentacja klasy *vertical* (stanowiącej niecałe 4% całego zbioru) jest kluczowym wyzwaniem w modelowaniu i może wymagać w późniejszych etapach zastosowania odpowiednich technik balansowania klas, takich jak oversampling (np. SMOTE) lub manipulacja wagami klas w wybranych algorytmach klasyfikacyjnych.

1.1.2 Analiza wartości odstających (Outlierów)

Do identyfikacji wartości odstających dla zmiennych numerycznych wykorzystano metodę rozstępu międzykwartylowego (IQR – *Interquartile Range*). Zidentyfikowano łącznie 85 wystąpień wartości wykraczających poza wyznaczone dolne i górne granice (wąsy pudełkowe) w poszczególnych cechach.

Najwięcej anomalii zaobserwowano m.in. dla kąta `12_Mn Base angle` (8 obserwacji), `12_SNPog` (7 obserwacji) oraz `12_SNB` (7 obserwacji). Dwie cechy – `9_ANB` oraz `12_AFH:PFH` - nie wykazały żadnych wartości odstających według przyjętego kryterium. Z uwagi na biomedyczny charakter zbioru danych, zidentyfikowane wartości najprawdopodobniej odzwierciedlają naturalną, rzadszą zmienność anatomiczną pacjentów i silne wady zgryzu, w związku z czym nie zdecydowano się na ich usunięcie.

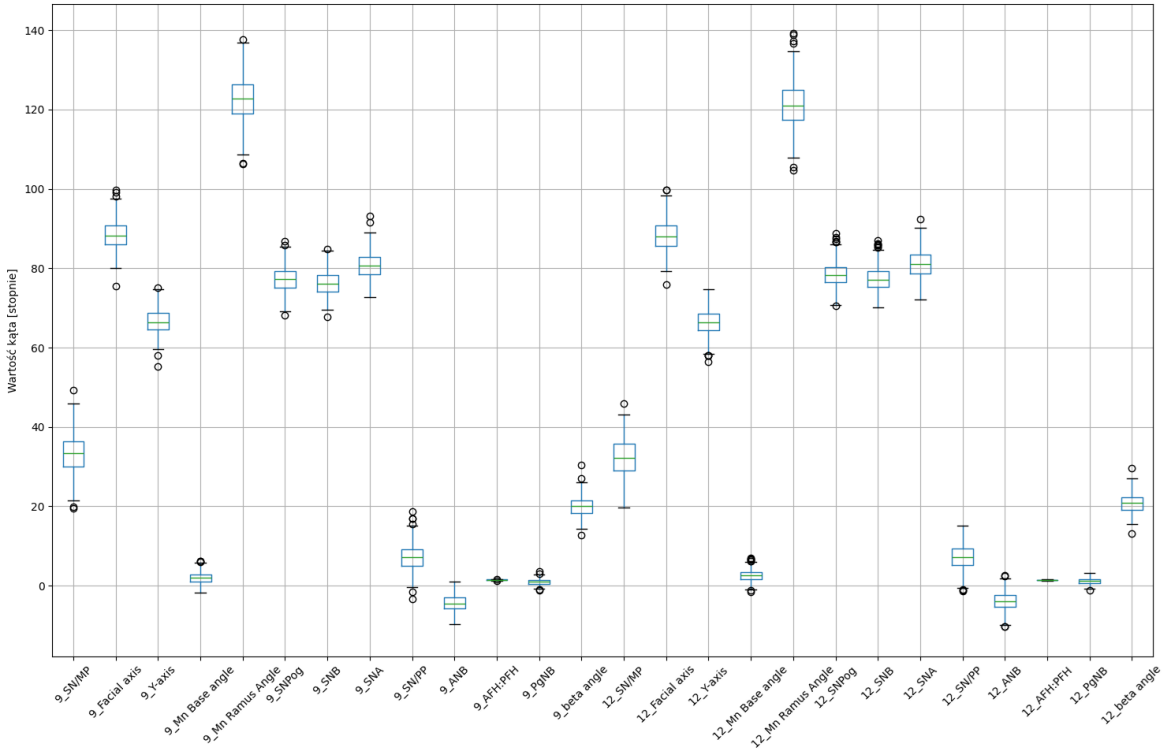

Rysunek 1: Wizualizacja wartości odstających

1.1.3 Analiza korelacji

W celu zbadania zależności liniowych między 26 zmiennymi objaśniającymi, wygenerowano macierz korelacji z zastosowaniem klastrowania hierarchicznego (Rysunek 2). Analiza wykresu ujawnia powszechne występowanie silnego zjawiska współliniowości.

Najbardziej zauważalną zależnością jest bardzo wysoka, dodatnia korelacja pomiędzy pomiarami tej samej cechy zarejestrowanymi w 9. i 12. roku życia. Wartości współczynnika korelacji dla tych par nierzadko przekraczają próg 0.8 (co jest szczególnie widoczne m.in. dla zmiennych `12_SNA` i `9_SNA`, a także `SN/MP`, `SNB` czy `Mn Ramus Angle`). Wskazuje to na istotny fakt anatomiczny: u większości pacjentów proporcje szkieletowe pozostają relatywnie stabilne w czasie rozwoju.

Ponadto widoczne są grupy cech silnie powiązanych w tym samym wieku pomiaru. Wiele z tych cech jest ze sobą powiązanych anatomicznie, co naturalnie prowadzi do powstawania silnych korelacji dodatnich i ujemnych. Przykładowo, zmienne takie jak `SN/MP`, `AFH:PFH`, `Facial axis` oraz `Y-axis` tworzą wyraźny blok o wysokiej korelacji dodatniej.

Występowanie tak licznych i silnych korelacji (wielowspółliniowość) wymaga zachowania szczególnej ostrożności podczas selekcji cech do modelu. Włączenie silnie skorelowanych zmiennych przeważnie nie wnosi dodatkowej mocy predykcyjne. Stanowi to silną przesłankę do rozważenia zastosowania metod redukcji wymiarowości.

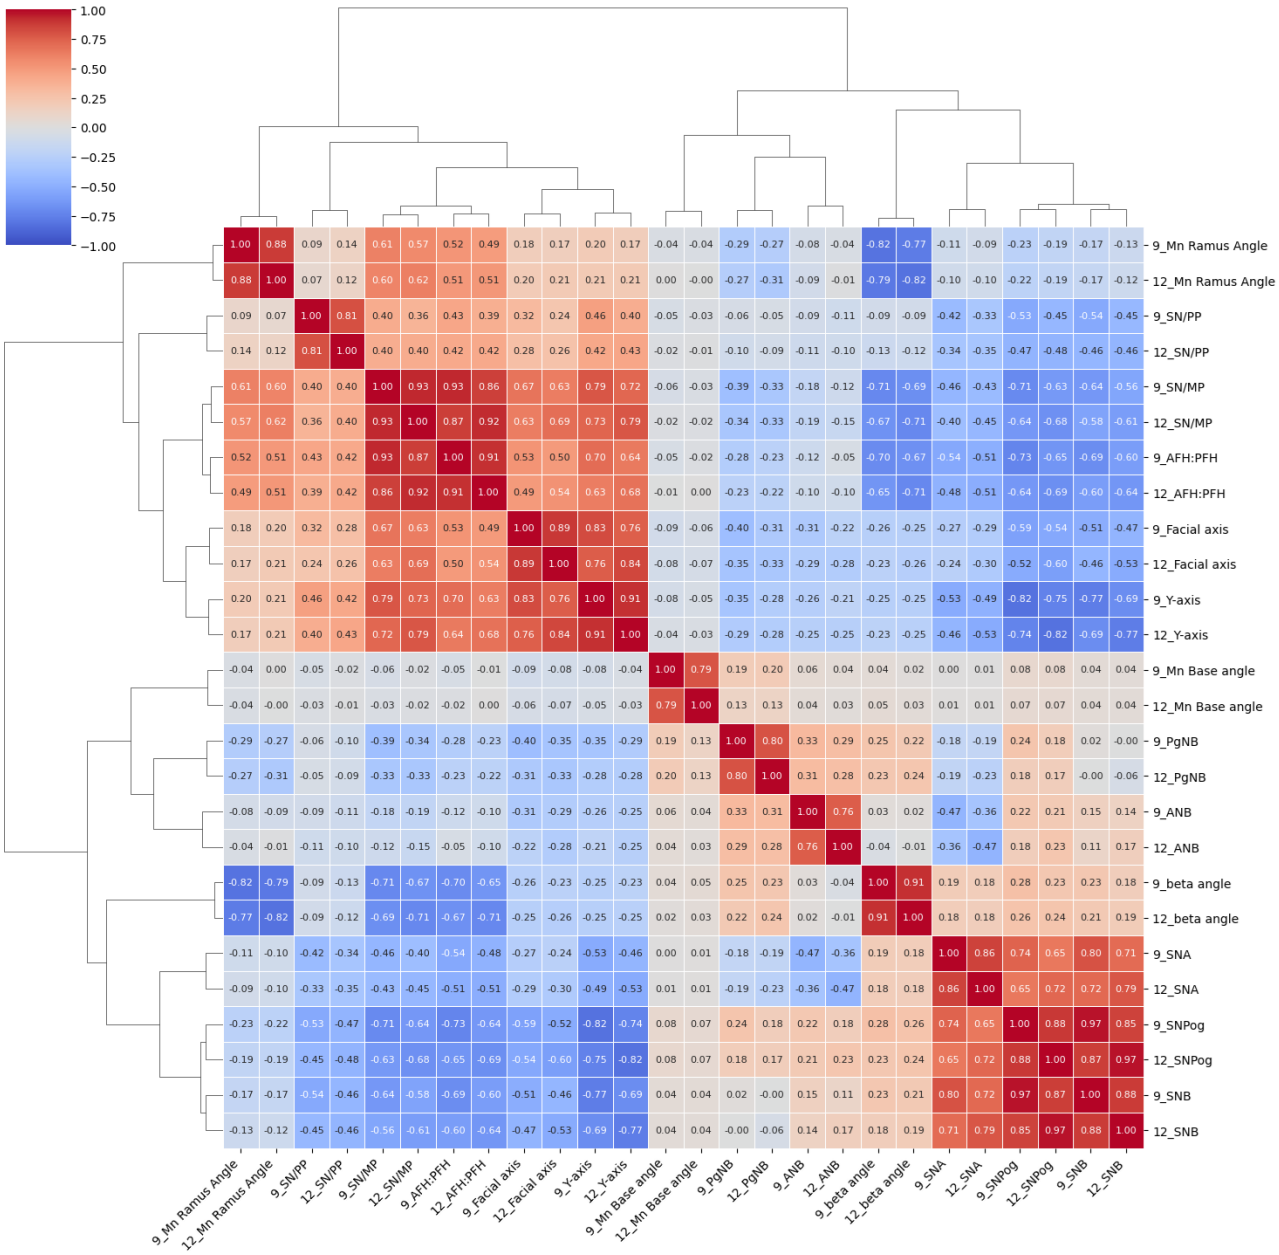

Rysunek 2: Macierz korelacji zmiennych

1.1.4 Standaryzacja danych

Z uwagi na fakt, że cechy opierają się na miarach kątowych i proporcjach o różnych zakresach i wariancjach, algorytmy podatne na skalę mogłyby faworyzować zmienne o większych wartościach bezwzględnych.

Aby temu zapobiec, przed algorytmem K-Nearest Neighbors, zbiór poddano procesowi standaryzacji (skalowania). Cechy zostały przekształcone w taki sposób, aby ich wartość oczekiwana (średnia) wynosiła 0, a odchylenie standardowe 1. W celu uniknięcia wycieku informacji, skaler został dopasowany wyłącznie na zbiorze treningowym, a następnie wykorzystany do transformacji zarówno zbioru uczącego, jak i testowego.

1.2 Kroswalidacja

W celu rzetelnej oceny algorytmów uczenia maszynowego oraz optymalizacji ich hiperparametrów, zastosowano zaawansowany schemat walidacji krzyżowej. Ze względu na losowość procesów uczenia, eksperymenty należy powtarzać, dlatego zdecydowano się na wykorzystanie powtórzonej walidacji krzyżowej.Skonfigurowano podział zbioru na 5 podzbiorów, a cały proces powtarzano 3-krotnie. Taka parametryzacja skutkuje przeprowadzeniem 15 niezależnych iteracji uczącotestujących dla każdego ewaluowanego modelu. Pozwala to na to, aby wyniki zostały opisane statystycznie z wykorzystaniem miar takich jak średnia i odchylenie standardowe. Takie podejście znacząco zwiększa wiarygodność ewaluacji i pozwala na rzetelną ocenę siły modelu.Kluczowym aspektem wybranego schematu jest jego warstwowość. Zbiór danych charakteryzuje się silnym niezrównoważeniem klas, co jest szczególnie widoczne na przykładzie klasy *vertical*, która liczy zaledwie 16 obserwacji. Zwykły losowy podział mógłby doprowadzić do sytuacji, w której ta mniejszościowa klasa w ogóle nie znalazłaby się w zbiorze testowym lub treningowym w danej iteracji. Mechanizm warstwowy rozwiązuje ten problem, gwarantując zachowanie oryginalnych proporcji klas we wszystkich wygenerowanych podzbiorach.

1.3 Drzewo Decyzyjne

1.3.1 Bazowe Drzewo Decyzyjne

Celem tego eksperymentu było stworzenie i ocena bazowego modelu drzewa decyzyjnego.

W procesie kroswalidacji model uzyskał średni wynik **F1-macro** na poziomie 0,5268±0,0812. Szczegółowe wyniki klasyfikacji na zbiorze testowym przedstawiono w Tabeli 1.

Tabela 1: Metryki klasyfikacji dla bazowego modelu Drzewa Decyzyjnego

Klasa	**Precision**	**Recall**	**F1-score**	**Support**
0	0,71	0,73	0,72	37
1	0,76	0,74	0,75	50
2	0,33	0,33	0,33	3
Accuracy	—		**0,72**	90
Macro avg	0,60	0,60	0,60	90
Weighted avg	0,72	0,72	0,72	90

Ponadto, na Rysunku 3 przedstawiono macierz pomyłek, która obrazuje trudności modelu w poprawnej klasyfikacji mniejszościowej klasy 2.

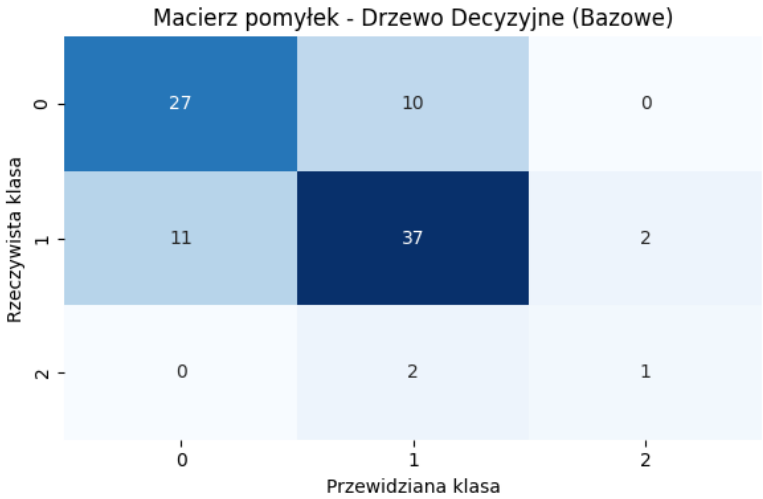

Rysunek 3: Macierz pomyłek dla bazowego modelu Drzewa Decyzyjnego

1.3.2 Drzewo Decyzyjne z techniką SMOTE

W kolejnym etapie eksperymentu sprawdzono wpływ techniki *oversamplingu* SMOTE na zdolność modelu do rozpoznawania klasy mniejszościowej (Klasa 2). Średni wynik F1-macro uzyskany w kroswalidacji wzrósł do $0{,}5908 \pm 0{,}1233$, jednak szczegółowa analiza na zbiorze testowym (Tabela 2) ujawniła istotne problemy modelu.

Tabela 2: Metryki klasyfikacji dla modelu Drzewa Decyzyjnego po zastosowaniu SMOTE

Klasa	**Precision**	**Recall**	**F1-score**	**Support**
0	0,70	0,76	0,73	37
1	0,76	0,74	0,75	50
2	0,00	0,00	0,00	3
Accuracy	—		**0,72**	90
Macro avg	0,49	0,50	0,49	90
Weighted avg	0,71	0,72	0,71	90

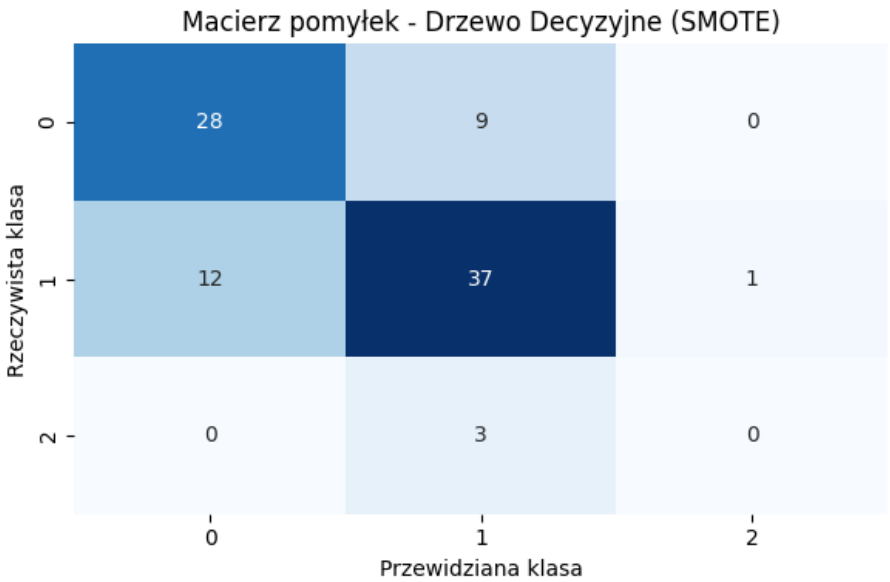

Rysunek 4: Macierz pomyłek dla modelu z SMOTE. Widoczny całkowity brak poprawnych klasyfikacji dla klasy 2.

Zastosowanie SMOTE wpłynęło negatywnie na stabilność modelu w odniesieniu do zbioru testowego. Choć wynik kroswalidacji sugerował poprawę, ostateczny wynik F1-score dla klasy 2 spadł do 0,00. Przyczyną tego stanu rzeczy jest prawdopodobnie zbyt mała liczność klasy mniejszościowej.

Algorytm SMOTE generuje syntetyczne próbki na podstawie k-najbliższych sąsiadów; przy ekstremalnie małej liczbie punktów, nowo utworzone dane mogą drastycznie odbiegać od rzeczywistego rozkładu, prowadząc do silnego *overfittingu* (przeuczenia) do szumu. W rezultacie model bazowy z poprzedniego etapu, mimo braku balansowania, radził sobie lepiej z ogólną generalizacją (F1-macro = 0,60) niż model wspomagany SMOTE (F1-macro = 0,49).

1.3.3 Optymalizacja Drzewa Decyzyjnego (Grid Search + SMOTE)

Kolejnym etapem pracy z pojedynczym drzewem decyzyjnym była próba optymalizacji hiperparametrów przy jednoczesnym zastosowaniu techniki SMOTE. Wykorzystano procedurę *Grid Search*.

W wyniku przeszukiwania przestrzeni parametrów wyłoniono optymalny model charakteryzujący się następującymi cechami:

- **Criterion:** entropy,
- **Max depth:** 5,
- **Min samples leaf:** 1,
- **Min samples split:** 2.

Model ten uzyskał najwyższy dotychczasowy średni wynik **F1-macro** w kroswalidacji wynoszący 0,6233 ± 0,1004. Szczegółowe metryki dla zbioru testowego zaprezentowano w Tabeli 3.

Tabela 3: Metryki klasyfikacji dla zoptymalizowanego modelu Drzewa Decyzyjnego (SMOTE + Grid Search)

Klasa	**Precision**	**Recall**	**F1-score**	**Support**
0	0,87	0,70	0,78	37
1	0,78	0,92	0,84	50
2	1,00	0,33	0,50	3
Accuracy	—		**0,81**	90
Macro avg	0,88	0,65	0,71	90
Weighted avg	0,82	0,81	0,80	90

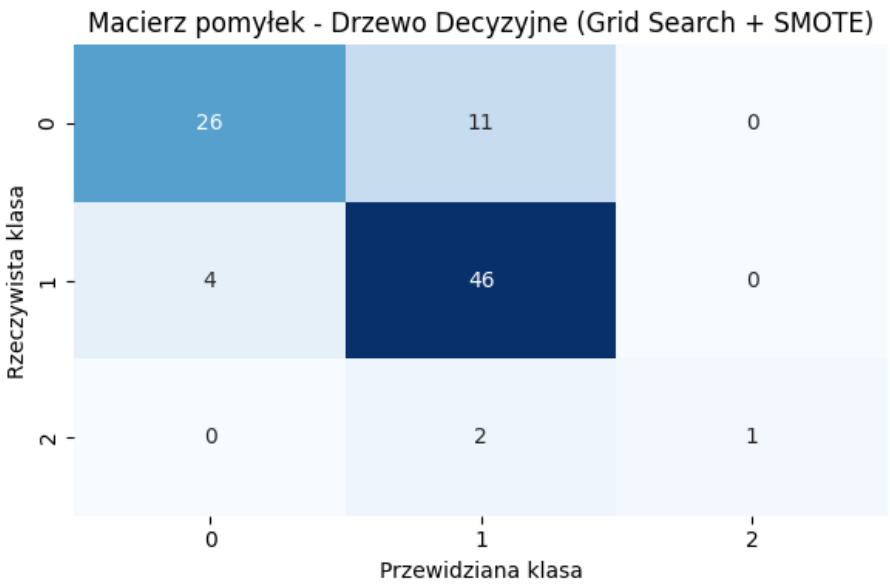

Rysunek 5: Macierz pomyłek dla zoptymalizowanego modelu. Widoczna poprawa w detekcji klasy 2.

Wprowadzenie optymalizacji hiperparametrów pozwoliło na skuteczne wykorzystanie potencjału techniki SMOTE. Kluczowe okazało się ograniczenie głębokości drzewa (`max_depth: 5`), co zapobiegło obserwowanemu wcześniej przeuczeniu do syntetycznych próbek.

Model po raz pierwszy poprawnie zidentyfikował obiekt z mniejszościowej klasy 2 (*Recall* = 0,33), utrzymując przy tym bardzo wysoką precyzję (1,00). Ogólna dokładność (*Accuracy*) wzrosła z 0,72 do 0,81, a miara **F1-macro** na zbiorze testowym osiągnęła poziom 0,71, co stanowi istotny progres względem modelu bazowego (0,60) oraz modelu SMOTE bez optymalizacji (0,49).

Inżynieria cech i zaawansowana optymalizacja (Engineering + SMOTE + GridSearch)

Ostatnim etapem pracy z pojedynczym drzewem decyzyjnym było zastosowanie inżynierii cech. Przeprowadzono następujące operacje:

- **Inżynieria cech:** Utworzono zmienne typu *Delta*, obliczając różnicę w pomiarach między 12. a 9. rokiem życia dla każdego parametru.
- **Selekcja cech:** Usunięto surowe dane z 9. roku życia (zawarte w delcie i pomiarach z 12. roku) oraz wyeliminowano zmienne o korelacji wyższej niż $0,9$ w celu redukcji wielowspółliniowości. Zredukowano liczbę cech do 23.

- **Modelowanie:** Zastosowano *ImbPipeline* łączący SMOTE z drzewem o zbalansowanych wagach klas (*class_ weight='balanced'*).

Najlepsze parametry wyłonione przez *Grid Search*: `criterion: gini, max_depth: 3, min_samples_l` `2, min_samples_split: 10`. Wyniki przedstawiono w Tabeli 4.

Tabela 4: Metryki dla modelu z inżynierią cech i optymalizacją

Klasa	Precision	Recall	F1-score	Support
0	0,90	0,70	0,79	37
1	0,85	0,88	0,86	50
2	0,33	1,00	0,50	3
Accuracy	—		**0,81**	90
Macro avg	0,69	0,86	0,72	90
Weighted avg	0,85	0,81	0,82	90

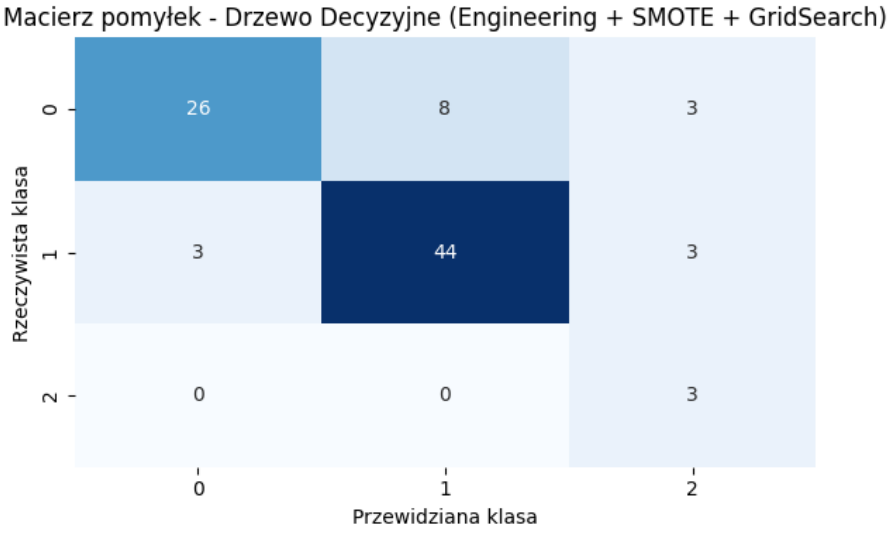

Rysunek 6: Macierz pomyłek dla modelu z inżynierią cech. Zwraca uwagę pełna wykrywalność klasy 2.

Wprowadzenie cech różnicowych (*Delta*) oraz agresywna redukcja wymiarowości przyniosły najlepszy rezultat pod względem czułości modelu. Kluczowym osiągnięciem jest uzyskanie **Recall = 1,00 dla klasy 2**, co oznacza, że model poprawnie zidentyfikował wszystkich pacjentów z grupy mniejszościowej.

Niska precyzja dla tej klasy $(0,33)$ przy jednoczesnym wzroście ogólnego **F1-macro do 0,72** sugeruje, że model stał się „liberalny" w diagnozowaniu klasy mniejszościowej (częstsze fałszywe alarmy). Bardzo płytkie drzewo (`max_depth: 3`) zapewnia doskonałą interpretowalność i odporność na przeuczenie.

1.4 Random Forest

1.4.1 Bazowy Random Forest

Celem tego eksperymentu było przetestowanie bazowego modelu Lasu Losowego, składającego się ze 100 drzew decyzyjnych. W procesie kroswalidacji model uzyskał średni wynik **F1-macro**

na poziomie 0,5602 ± 0,0869. Szczegółowa analiza metryk wykazuje istotne problemy z rozpoznawaniem klas mniejszościowych.

Szczegółowe wyniki klasyfikacji na zbiorze testowym przedstawiono w Tabeli 5.

Tabela 5: Metryki klasyfikacji dla bazowego modelu Random Forest

Klasa	**Precision**	**Recall**	**F1-score**	**Support**
0	0,88	0,81	0,85	37
1	0,82	0,92	0,87	50
2	0,00	0,00	0,00	3
Accuracy	—		**0,84**	90
Macro avg	0,57	0,58	0,57	90
Weighted avg	0,82	0,84	0,83	90

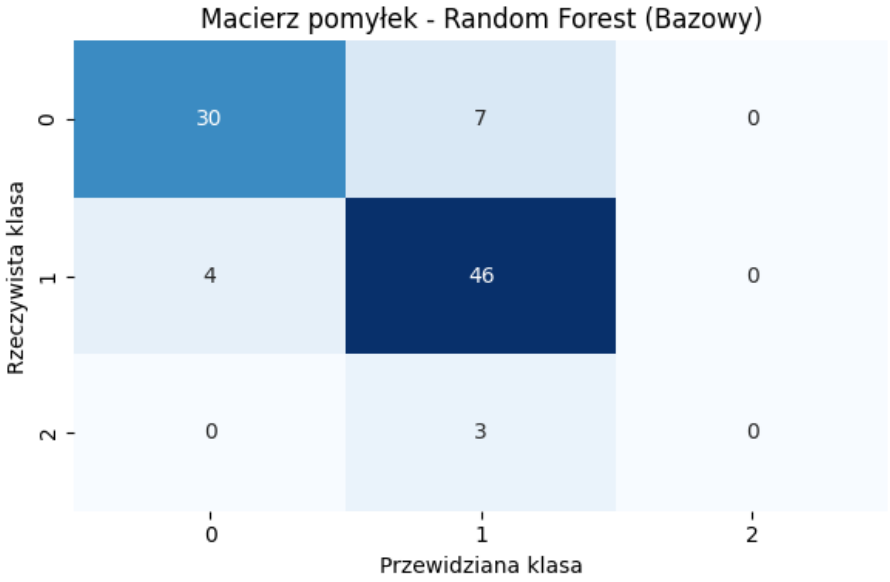

Rysunek 7: Macierz pomyłek dla modelu Random Forest

Model Random Forest osiągnął bardzo wysoką ogólną dokładność (*Accuracy* = 0,84). Bardzo dobrze radzi sobie z odróżnianiem klasy 0 (*normal*) i 1 (*horizontal*), uzyskując dla nich wyniki F1-score na poziomie 0,85-0,87. Podobnie jak w przypadku bazowego drzewa decyzyjnego, algorytm całkowicie zignorował klasę 2 (*vertical*). Wartości precyzji i czułości dla tej klasy wynoszą 0,00.

Wyniki te wskazują na konieczność zastosowania metod balansowania klas, takich jak SMOTE lub korekta wag klas (*class_ weight*), w celu poprawy zdolności predykcyjnej modelu dla rzadkich przypadków medycznych.

1.4.2 Random Forest z techniką SMOTE

Kolejnym etapem było sprawdzenie skuteczności lasu losowego po zastosowaniu algorytmu *oversamplingu* SMOTE wewnątrz potoku przetwarzania (*pipeline*). Celem było zniwelowanie negatywnego wpływu niezrównoważenia klas na zdolność modelu do detekcji rzadkich przypadków (*vertical growth*).

W procesie kroswalidacji model uzyskał średni wynik **F1-macro** na poziomie 0,6594±0,1142, co stanowi istotną poprawę względem wersji bazowej (0,5602). Szczegółowe metryki uzyskane na zbiorze testowym zaprezentowano w Tabeli 6.

Tabela 6: Metryki klasyfikacji dla modelu Random Forest z techniką SMOTE

Klasa	**Precision**	**Recall**	**F1-score**	**Support**
0	0,86	0,84	0,85	37
1	0,87	0,90	0,88	50
2	1,00	0,67	0,80	3
Accuracy	—		**0,87**	90
Macro avg	0,91	0,80	0,84	90
Weighted avg	0,87	0,87	0,87	90

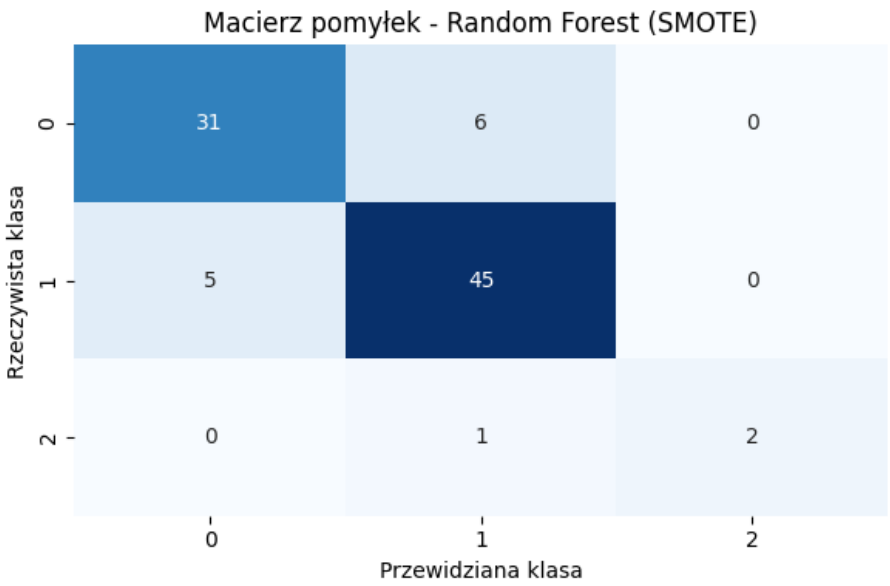

Rysunek 8: Macierz pomyłek dla modelu Random Forest

Zastosowanie SMOTE pozwoliło modelowi na skuteczną identyfikację klasy 2. Uzyskanie *Recall* na poziomie 0,67 (przy perfekcyjnej precyzji 1,00) oznacza, że model poprawnie rozpoznał 2 z 3 przypadków mniejszościowych, nie generując przy tym żadnych fałszywych alarmów (*False Positives*) dla tej klasy. Ogólna dokładność (*Accuracy*) wzrosła do poziomu 0,87, a miara **F1-macro** na zbiorze testowym osiągnęła bardzo wysoki wynik **0,84**. Jest to znaczący progres w stosunku do modelu bazowego (0,57). Mimo skupienia się na balansowaniu danych, model utrzymał bardzo wysoką skuteczność dla klas 0 i 1 (F1-score odpowiednio 0,85 i 0,88), co świadczy o dobrej generalizacji i braku negatywnego wpływu syntetycznych próbek na główne trendy w danych.

Model Random Forest połączony z techniką SMOTE okazał się dotychczas najbardziej zbalansowanym i skutecznym klasyfikatorem, oferującym wysoką precyzję przy jednoczesnej zdolności do wykrywania przypadków odstających anatomicznie.

1.4.3 Optymalizacja Random Forest (Grid Search + SMOTE)

W celu dalszej poprawy zdolności predykcyjnych oraz stabilności modelu, przeprowadzono optymalizację hiperparametrów lasu losowego przy użyciu procedury *Grid Search*. Proces ten połączono z techniką balansowania SMOTE w ramach potoku przetwarzania, co pozwoliło na przeszukanie 216 kombinacji parametrów w 15 iteracjach kroswalidacji.

W wyniku optymalizacji wyłoniono model o następujących parametrach:

- **n_estimators:** 100,
- **max_depth:** None (brak ograniczenia),
- **max_features:** 'sqrt',
- **min_samples_leaf:** 1,
- **min_samples_split:** 10.

Zoptymalizowany model uzyskał najwyższy dotychczas średni wynik **F1-macro** w kroswalidacji wynoszący $0{,}6774 \pm 0{,}0999$ (poprawa względem 0,6594 dla modelu SMOTE bez optymalizacji). Szczegółowe metryki dla zbioru testowego zaprezentowano w Tabeli 7.

Tabela 7: Metryki klasyfikacji dla zoptymalizowanego modelu Random Forest (Grid Search + SMOTE)

Klasa	**Precision**	**Recall**	**F1-score**	**Support**
0	0,86	0,84	0,85	37
1	0,87	0,90	0,88	50
2	1,00	0,67	0,80	3
Accuracy	—		**0,87**	90
Macro avg	0,91	0,80	0,84	90
Weighted avg	0,87	0,87	0,87	90

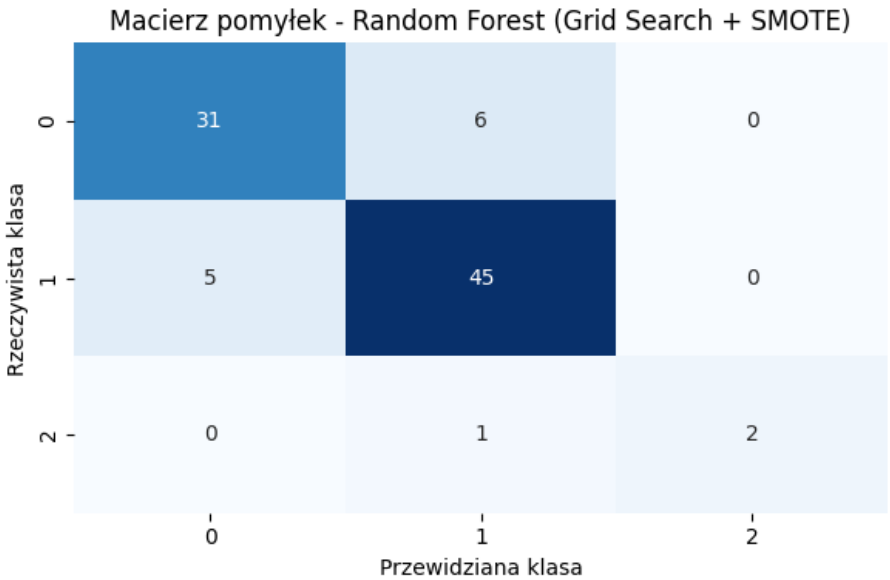

Rysunek 9: Macierz pomyłek dla zoptymalizowanego modelu Random Forest

Choć wyniki na zbiorze testowym są zbliżone do modelu przed optymalizacją, wzrost średniego wyniku kroswalidacji (z 0,66 na 0,68) oraz niższe odchylenie standardowe wskazują na lepszą zdolność modelu do generalizacji na nieznanych danych. Model utrzymał bardzo wysoką precyzję dla klasy 2 (1,00), poprawnie klasyfikując 2 z 3 przypadków.

1.4.4 Efektywna czasowo optymalizacja Random Forest (Randomized Search + SMOTE)

Kluczowym aspektem tego eksperymentu była wydajność obliczeniowa. Podczas gdy poprzedni model optymalizowany metodą Grid Search wymagał 1 minuty i 23 sekund na znalezienie najlepszych parametrów, Randomized Search zakończył pracę w zaledwie 43 sekundy, co stanowi niemal dwukrotne przyspieszenie procesu przy zachowaniu zbliżonej jakości predykcji.

W wyniku losowania 50 kombinacji wyłoniono model o parametrach:

- **n_estimators:** 487,
- **max_depth:** 40,
- **max_features:** 'sqrt',
- **min_samples_leaf:** 3,
- **min_samples_split:** 3.

Średni wynik **F1-macro** w kroswalidacji wyniósł 0,6752 ± 0,0954. Szczegółowe wyniki na zbiorze testowym przedstawiono w Tabeli 8.

Tabela 8: Metryki klasyfikacji dla modelu Random Forest (Randomized Search + SMOTE)

Klasa	**Precision**	**Recall**	**F1-score**	**Support**
0	0,83	0,81	0,82	37
1	0,85	0,88	0,86	50
2	1,00	0,67	0,80	3
Accuracy	—		**0,84**	90
Macro avg	0,89	0,79	0,83	90
Weighted avg	0,85	0,84	0,84	90

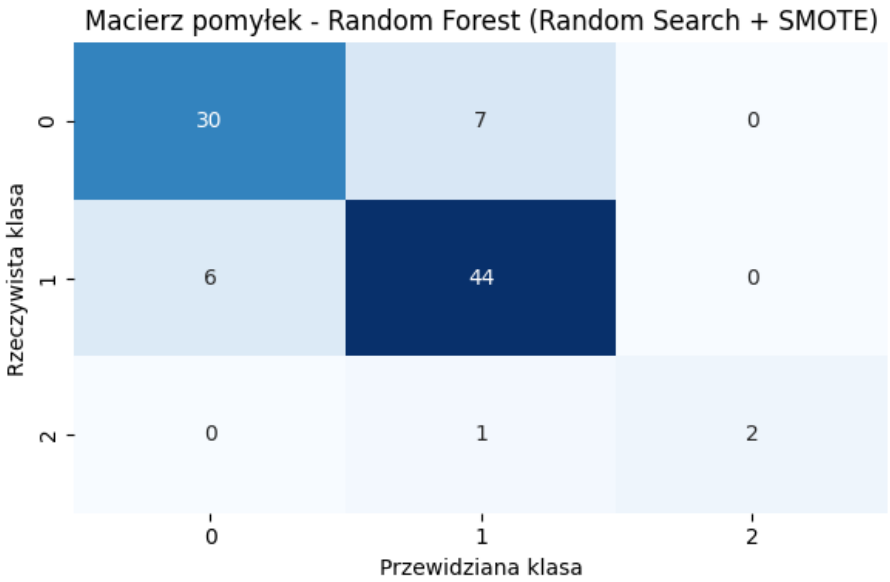

Rysunek 10: Macierz pomyłek dla Randomized Search modelu Random Forest

Randomized Search okazał się znacznie efektywniejszy czasowo. Pozwoliło to na przetestowanie znacznie większej liczby drzew (487 zamiast 100) bez nadmiernego obciążenia zasobów.

Wynik F1-macro dla klasy 2 pozostał na wysokim poziomie 0,80 (Recall 0,67). Oznacza to, że mimo szybszego procesu optymalizacji, model nie stracił zdolności do detekcji rzadkich przypadków patologicznych. Choć ogólna dokładność (*Accuracy* = 0,84) jest nieznacznie niższa niż w przypadku pełnej siatki (0,87), model ten uczy się 2 razy szybciej.

1.4.5 Zaawansowana inżynieria cech (Engineering + Ratios + SMOTE)

Wzorując się na sukcesie inżynierii cech w bazowym drzewie decyzyjnym, zdecydowano się na wdrożenie analogicznego, lecz poszerzonego procesu dla algorytmu Random Forest. Z uwagi na powszechne w zbiorze zjawisko wielowspółliniowości, które wymaga szczególnej ostrożności podczas selekcji cech, zastosowano wieloetapowe przekształcenia danych:

- **Cechy różnicowe (Deltas):** Wyliczono dynamikę zmian wymiarów poprzez odjęcie wyników z 9. roku życia od wyników z 12. roku życia.
- **Wskaźniki proporcji (Ratios):** Na podstawie wiedzy domenowej i wcześniejszej macierzy korelacji, utworzono wskaźniki (m.in. relację szczęki do żuchwy `SNA`/`SNB` oraz relacje podstaw czaszki `NL`/`NSL`).
- **Eliminacja szumu:** Usunięto surowe pomiary z 9. roku życia, pozostawiając jedynie informacje o stanie końcowym (wiek 12) oraz wektorze zmian (Deltas).
- **Redukcja współliniowości:** Aby zapobiec wprowadzaniu redundantnych informacji, na podstawie zbioru treningowego usunięto cechy, których współczynnik korelacji przekraczał próg $0,95$.

Model zbudowano w oparciu o potok uwzględniający algorytm SMOTE oraz zbalansowane wagi klas (`class_weight='balanced'`). Optymalizacja *Grid Search* wyłoniła parametry zapobiegające przeuczeniu: `max_depth: 5`, `max_features: 'sqrt'`, `min_samples_leaf: 4` oraz `n_estimators: 500`.

Średni wynik **F1-macro** w kroswalidacji osiągnął $0{,}6387 \pm 0{,}1001$. Mimo pozornie niższego wyniku średniego w stosunku do poprzednich iteracji, ewaluacja na zbiorze testowym zaprezentowała dobre rezultaty (Tabela 9).

Tabela 9: Metryki dla zoptymalizowanego modelu Random Forest z zaawansowaną inżynierią cech

Klasa	**Precision**	**Recall**	**F1-score**	**Support**
0	0,81	0,81	0,81	37
1	0,86	0,84	0,85	50
2	0,75	1,00	0,86	3
Accuracy	—		**0,83**	90
Macro avg	0,81	0,88	0,84	90
Weighted avg	0,83	0,83	0,83	90

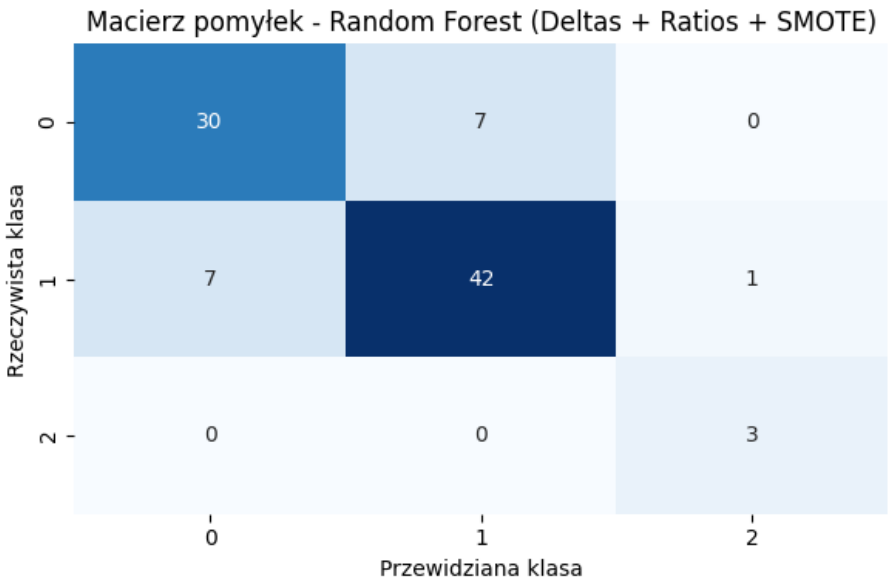

Rysunek 11: Macierz pomyłek dla modelu Random Forest z inżynierią cech.

Jest to najlepszy z dotychczasowych wariantów algorytmu Random Forest w kontekście detekcji klasy mniejszościowej. Uzyskanie czułości (*Recall*) na poziomie $1,00$ oznacza bezbłędne rozpoznanie wszystkich patologicznych przypadków *vertical*, pomimo że stanowią one zaledwie 16 obserwacji w całym zbiorze.

1.5 K-Nearest Neighbors

1.5.1 Bazowy algorytm K-Nearest Neighbors

W pierwszym kroku ewaluacji poddano bazowy wariant algorytmu K-Najbliższych Sąsiadów (KNN). Z uwagi na fakt, że KNN opiera swoje działanie na miarach odległości pomiędzy punktami, kluczowym elementem potoku przetwarzania (*pipeline*) była standaryzacja danych za pomocą `StandardScaler`. W procesie kroswalidacji model uzyskał średni wynik **F1-macro** na poziomie $0{,}5003 \pm 0{,}0673$.

Szczegółowe wyniki klasyfikacji na zbiorze testowym przedstawiono w Tabeli 10.

Tabela 10: Metryki klasyfikacji dla bazowego modelu KNN

Klasa	**Precision**	**Recall**	**F1-score**	**Support**
0	0,80	0,76	0,78	37
1	0,78	0,86	0,82	50
2	0,00	0,00	0,00	3
Accuracy	—		**0,79**	90
Macro avg	0,53	0,54	0,53	90
Weighted avg	0,76	0,79	0,77	90

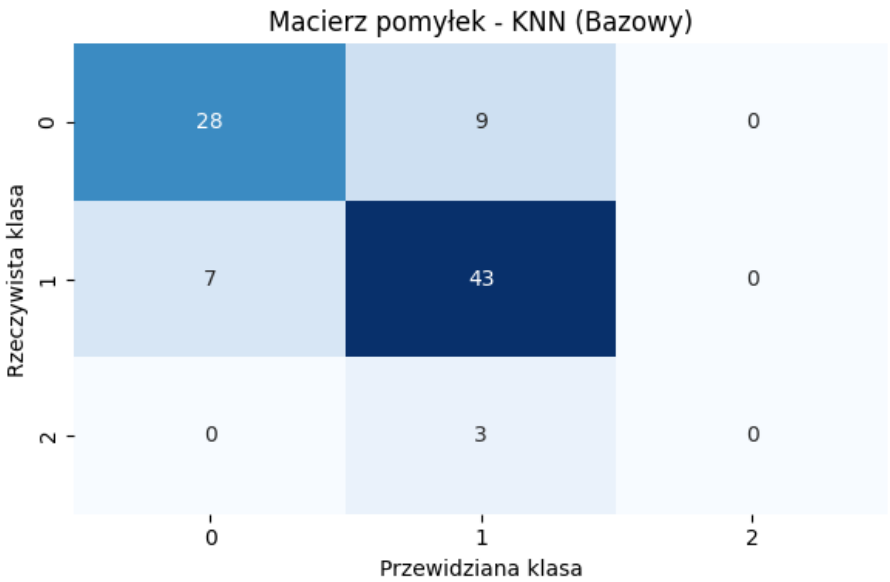

Rysunek 12: Macierz pomyłek dla bazowego modelu KNN

Podobnie jak w przypadku bazowych wersji Drzewa Decyzyjnego i Lasu Losowego, podstawowy algorytm KNN wykazuje całkowitą niezdolność do detekcji klasy 2 (*vertical*). Przypisywanie obserwacji wyłącznie do klas większościowych zaowocowało ostrzeżeniem środowiska o zerowej precyzji (*UndefinedMetricWarning*), co jednoznacznie potwierdza konieczność zastosowania technik balansowania danych.

1.5.2 K-Nearest Neighbors z techniką SMOTE

Aby rozwiązać problem niedoreprezentowanej klasy, do potoku przetwarzania (pomiędzy skaler a klasyfikator) wprowadzono algorytm *oversamplingu* SMOTE. W procesie kroswalidacji średni wynik **F1-macro** modelu wzrósł do $0{,}5537 \pm 0{,}0861$.

Tabela 11: Metryki klasyfikacji dla modelu KNN z techniką SMOTE

Klasa	**Precision**	**Recall**	**F1-score**	**Support**
0	0,72	0,84	0,78	37
1	0,88	0,72	0,79	50
2	0,50	1,00	0,67	3
Accuracy	—		**0,78**	90
Macro avg	0,70	0,85	0,74	90
Weighted avg	0,80	0,78	0,78	90

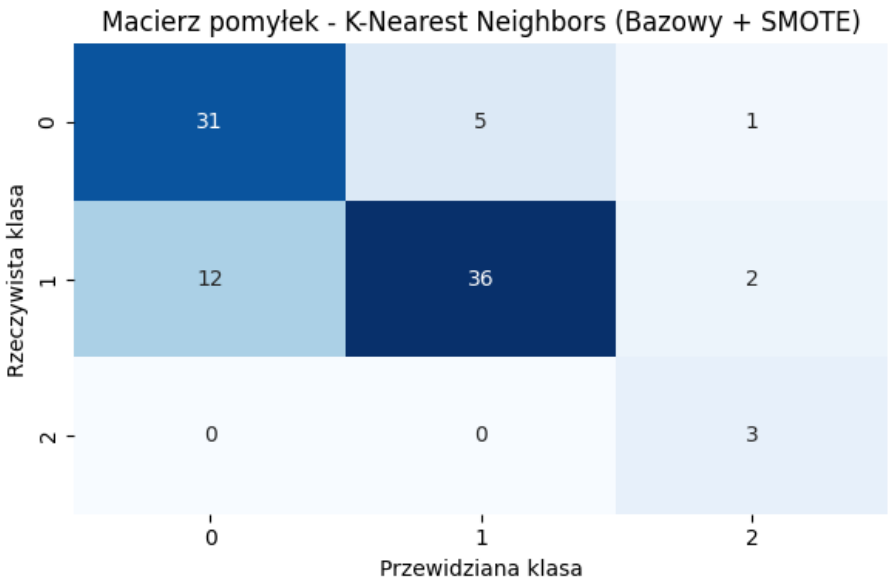

Rysunek 13: Macierz pomyłek dla modelu KNN z techniką SMOTE

Zastosowanie SMOTE przyniosło radykalną poprawę. Czułość (*Recall*) dla klasy 2 osiągnęła poziom 1,00, co oznacza bezbłędne zidentyfikowanie wszystkich przypadków patologicznych ze zbioru testowego. Mimo iż precyzja dla tej klasy wynosi 0,50 (pojawiają się fałszywe alarmy), to ogólna miara F1-macro wzrosła z 0,53 do 0,74 przy jedynie marginalnym spadku ogólnej trafności (*Accuracy* = 0,78 względem 0,79).

1.5.3 Optymalizacja K-Nearest Neighbors (Grid Search + SMOTE)

W kolejnym kroku przeprowadzono optymalizację hiperparametrów za pomocą *Grid Search*. Przeszukiwano m.in. liczbę sąsiadów, metryki odległości (parametr p) oraz typ wag. Optymalny model charakteryzował się następującymi parametrami:

- **n_neighbors:** 9,
- **metric:** minkowski,
- **p:** 2 (odległość euklidesowa),
- **weights:** uniform.

Średni wynik kroswalidacji uległ poprawie, osiągając **F1-macro** równe $0{,}5773 \pm 0{,}0699$.

Tabela 12: Metryki klasyfikacji dla zoptymalizowanego modelu KNN (Grid Search + SMOTE)

Klasa	**Precision**	**Recall**	**F1-score**	**Support**
0	0,71	0,86	0,78	37
1	0,89	0,68	0,77	50
2	0,43	1,00	0,60	3
Accuracy	—		**0,77**	90
Macro avg	0,68	0,85	0,72	90
Weighted avg	0,80	0,77	0,77	90

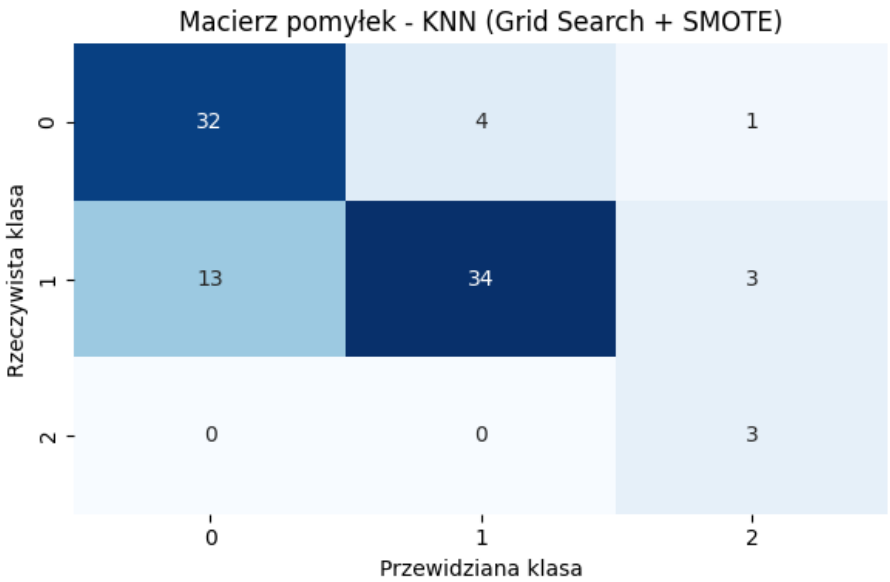

Rysunek 14: Macierz pomyłek dla zoptymalizowanego modelu KNN

Zwiększenie liczby rozpatrywanych sąsiadów do 9 pozwoliło modelowi uogólniać wiedzę lepiej (wyższy wynik kroswalidacji), choć nie przełożyło się to na drastyczny wzrost metryk na zbiorze testowym w stosunku do wariantu domyślnego. Model utrzymał maksymalną czułość dla rzadkiej klasy 2.

1.5.4 Zaawansowana inżynieria cech (Deltas + PCA + SMOTE + GridSearch)

W ostatnim eksperymencie z algorytmem KNN zastosowano złożony potok przetwarzania. Wzorując się na poprzednich algorytmach, obliczono zmienne różnicowe (*Deltas*). Z uwagi na podatność KNN na zjawisko „klątwy wymiarowości" oraz wysoki poziom korelacji cech, wprowadzono redukcję wymiarowości za pomocą Analizy Głównych Składowych (PCA), zachowując 95% wariancji.

Wynik *Grid Search* wyłonił optymalne parametry (`n_neighbors: 3, p: 2, weights: uniform`), a model uzyskał wynik CV na poziomie 0,5387±0,0614. Ewaluacja na zbiorze testowym ujawniła jednak poważne problemy tego podejścia (Tabela 13).

Tabela 13: Metryki dla modelu KNN z inżynierią cech i PCA

Klasa	**Precision**	**Recall**	**F1-score**	**Support**
0	0,49	0,62	0,55	37
1	0,66	0,46	0,54	50
2	0,38	1,00	0,55	3
Accuracy	—		**0,54**	90
Macro avg	0,51	0,69	0,54	90
Weighted avg	0,58	0,54	0,54	90

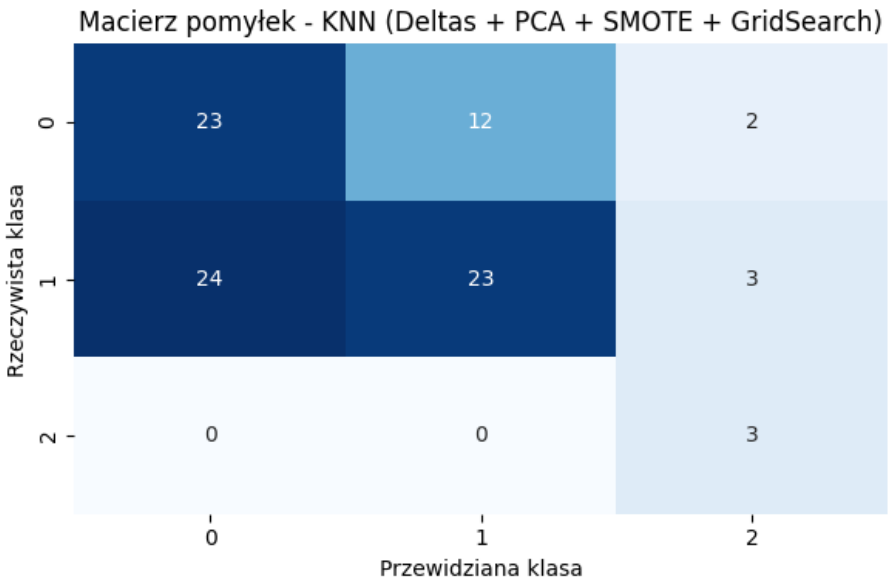

Rysunek 15: Macierz pomyłek dla modelu KNN z zaawansowaną inżynierią cech

W przeciwieństwie do modelu Random Forest, transformacja cech w połączeniu z redukcją przestrzeni (PCA) doprowadziła do drastycznego spadku ogólnej trafności klasyfikatora (*Accuracy* na poziomie 0,54). Chociaż model wciąż doskonale wykrywa klasę 2 (*Recall* równe 1,00), całkowicie zatracił zdolność precyzyjnego rozróżniania klas 0 i 1. Dowodzi to, że transformacja przestrzeni cech poprzez PCA zaburzyła oryginalne metryki odległości, na których opiera się KNN, prowadząc do znacznej utraty skuteczności na klasach większościowych. W przypadku tego zbioru danych, algorytmy oparte na zespołach drzew (Random Forest) radzą sobie ze skomplikowaną inżynierią cech znacznie lepiej niż algorytmy oparte na odległości.

1.6 Wnioski końcowe

Na podstawie uzyskanych wyników można sformułować następujące wnioski:

- **Zespoły drzew decyzyjnych dominują:** Algorytm Random Forest okazał się najbardziej stabilnym i skutecznym modelem. Jego zoptymalizowana wersja z inżynierią cech osiągnęła imponującą czułość (*Recall* = 1,00) dla klasy mniejszościowej przy zachowaniu wysokiej ogólnej dokładności (*Accuracy* = 0,83).

- **Synergia inżynierii cech i wiedzy domenowej:** Wprowadzenie zmiennych różnicowych (*Deltas*) oraz wskaźników proporcji (*Ratios*) znacząco podniosło zdolności predykcyjne modeli opartych na drzewach. Zastąpienie surowych pomiarów dynamiką zmian zredukowało szum informacyjny i ułatwiło algorytmom odnalezienie kluczowych reguł.

- **Ostrożność przy oversamplingu:** Zastosowanie techniki SMOTE było niezbędne do wykrycia klasy mniejszościowej, jednak bez odpowiedniej regularyzacji hiperparametrów (np. drastycznego ograniczenia głębokości drzewa) prowadziło to do silnego przeuczenia modelu na syntetycznym szumie.

- **Ograniczenia algorytmów opartych na odległości:** Algorytm K-Nearest Neighbors okazał się najmniej przystosowany do natury tego zbioru danych. Próba zaawansowanej redukcji wymiarowości (PCA) w celu zniwelowania współliniowości całkowicie zaburzyła metryki odległości, drastycznie pogarszając zdolności klasyfikacyjne modelu.

Ostatecznie, modelem rekomendowanym do ewentualnego wdrożenia wspomagającego diagnozę lub do dalszych testów jest zoptymalizowany **Random Forest połączony z inżynierią cech i algorytmem SMOTE**.

1.7 Propozycje dalszych badań

Z uwagi na specyfikę biomedycznych danych analitycznych oraz napotkane wyzwania, proponuje się następujące kierunki dalszych prac rozwojowych:

- **Rozszerzenie zbioru danych:** Najbardziej naturalnym i pożądanym krokiem jest pozyskanie większej liczby danych pacjentów z patologicznym kierunkiem wzrostu (*vertical*). Zwiększenie rzeczywistej reprezentacji tej klasy pozwoliłoby na weryfikację modeli bez konieczności polegania na sztucznym oversamplingu.

- **Testowanie algorytmów Gradient Boosting:** Warto sprawdzić skuteczność nowoczesnych algorytmów wzmacniania gradientowego (np. XGBoost, LightGBM, CatBoost), które natywnie świetnie radzą sobie z danymi tabelarycznymi i oferują wbudowane, zoptymalizowane mechanizmy obsługi niezrównoważonych klas.

- **Uczenie wrażliwe na koszty (Cost-sensitive learning):** Zamiast generować syntetyczne próbki (SMOTE), alternatywnym podejściem jest modyfikacja funkcji kosztu algorytmów tak, aby błąd w klasyfikacji rzadkiej klasy 2 był karany znacznie surowiej niż pomyłki w klasach większościowych.

- **Zaawansowane techniki resamplingu:** Eksploracja hybrydowych metod balansowania danych, takich jak SMOTE-ENN czy SMOTE-Tomek Links. Metody te oprócz generowania nowych próbek, usuwają również szum i obserwacje z pogranicza klas, co mogłoby poprawić precyzję (zmniejszyć liczbę fałszywych alarmów dla rzadkich diagnoz).